

CSC-4MI04 - Reconnaissance d'Images

TP2 : Classification de caractéristiques locales

Approches supervisée (bayésienne) et non supervisée (K-Means) - Reconnaissance d'Images

QUINTELLA PINTO Alfredo

GOMES BIAGGI Naomy

MOCZYDLOWER Carolina

Encadrant :

MANZANERA Antoine

HARIAT Marwane

Février 2026

Introduction

La classification de caractéristiques locales dans les images constitue une étape fondamentale dans diverses applications de vision par ordinateur, telles que la segmentation, la reconnaissance de formes et l'analyse de scènes. Ce domaine d'étude s'appuie sur deux approches principales : l'approche supervisée, qui utilise des données préalablement étiquetées pour construire un modèle prédictif, et l'approche non supervisée, qui regroupe les données en fonction de similarités intrinsèques, sans nécessiter d'étiquettes préalables.

Dans le cadre de ce travail pratique, l'accent est mis sur l'application de ces approches à la segmentation d'images, plus précisément par la classification de pixels. Deux méthodes paradigmatiques sont explorées : la classification bayésienne, qui s'appuie sur des principes probabilistes pour déduire la classe d'un pixel en fonction de ses caractéristiques observées, et l'algorithme K-Means, une technique de regroupement non supervisée qui partitionne les données en un nombre prédéfini de clusters.

L'objectif de ce rapport est de décrire la mise en œuvre, l'analyse critique et les résultats obtenus dans la résolution d'un problème concret de segmentation : l'identification de la région pavée (route) dans les scènes routières de l'ensemble de données KITTI. Cette tâche est cruciale pour les systèmes de conduite assistée et autonome, où la délimitation correcte de la voie navigable est essentielle pour la sécurité et la prise de décision.

La structure du rapport suit le guide proposé, en commençant par la préparation de l'environnement et l'exploration des données, puis en appliquant et comparant les méthodologies de classification bayésienne (approche supervisée) et K-Means (approche non supervisée), pour aboutir à une discussion sur les défis rencontrés, les décisions prises et les conclusions concernant l'efficacité de chaque méthode pour la tâche en question. Des résultats visuels et des analyses quantitatives seront présentés pour étayer les observations et les critiques élaborées tout au long du travail.

Prérequis et environnement de travail

Les codes utilisés dans ce travail sont basés sur ceux mis à disposition sur ([Lien Codes](#)) et les images d'expérimentation sur ([Lien Images](#)). L'ensemble des contenus produits par notre groupe se trouve dans le dépôt Github ([Lien Github](#))

Principes de la classification bayésienne

Principes généraux

La classification bayésienne est une approche probabiliste de la classification qui repose sur le théorème de Bayes. Son objectif est d'assigner à une observation x la classe C_k la plus probable compte tenu des données observées.

Le principe fondamental consiste à modéliser la probabilité a posteriori d'une classe sachant l'observation, notée $P(C_k|x)$, à partir de la vraisemblance $P(x|C_k)$, de la probabilité a priori $P(C_k)$ et de la vraisemblance totale $P(x)$, via la relation :

$$P(C_k|x) = \frac{P(x|C_k)P(C_k)}{P(x)}.$$

La règle de décision bayésienne consiste alors à choisir la classe qui maximise cette probabilité a posteriori (MAP - Maximum A posteriori).

- **L'estimation par maximum de vraisemblance (MV)** : on suppose que les classes sont équiprobables et on maximise $P(x|C_k)$. Cette approche est notamment utilisée dans le classifieur naïf de Bayes lorsque les distributions des caractéristiques sont estimées à partir des données.
- **L'estimation par maximum a posteriori (MAP)** : on tient compte des probabilités a priori des classes, ce qui peut être utile lorsque certaines classes sont plus rares que d'autres.

La classification bayésienne constitue ainsi un cadre théorique cohérent pour la prise de décision en présence d'incertitude.

Question 1

Quelle différence y a-t-il entre la classification par le critère du maximum de vraisemblance (ML) et celui du maximum a posteriori (MAP) ? Comment cette différence se traduira-t-elle dans vos programmes ?

La différence fondamentale entre le critère du maximum de vraisemblance (ML - Maximum Likelihood) et celui du maximum a posteriori (MAP - Maximum A Posteriori) réside dans la prise en compte ou non des probabilités a priori des classes.

- **Maximum de Vraisemblance (ML)** : on sélectionne la classe C_k qui maximise $P(x|C_k)$, c'est-à-dire la vraisemblance des observations sachant la classe. Cette approche suppose implicitement que toutes les classes sont équiprobables ($P(C_k) = \frac{1}{K}$) ou ignore complètement leur distribution a priori.
- **Maximum a posteriori (MAP)** : on sélectionne la classe C_k qui maximise $P(C_k|x)$, la probabilité a posteriori. D'après le théorème de Bayes, cela revient à maximiser $P(x|C_k)P(C_k)$, puisque $P(x)$ est un facteur de normalisation constant pour toutes les classes. On intègre donc ici la connaissance éventuelle sur la fréquence d'apparition des classes.

Pour notre programme, la principale différence apparaît dans *QuadraticDiscriminantAnalysis*. Lorsque nous définissons *priors=None*, nous utilisons les fréquences réelles des ROI ; les probabilités a priori sont donc estimées, et nous appliquons la règle MAP. Si nous définissons *priors=[0.5, 0.5]*, nous imposons des classes équiprobables et nous appliquons donc le critère du maximum de vraisemblance (ML).

Application à la classification bayésienne des pixels

La segmentation d'images basée sur la couleur consiste à utiliser les valeurs de chaque pixel pour séparer les régions d'intérêt. Pour cela, nous pouvons représenter la couleur des pixels dans différents espaces, chacun ayant ses avantages et ses limites.

1. RGB : Représente directement les canaux Red, Green et Blue capturés par le capteur de la caméra.

Focus : utile lorsque la couleur pure des objets suffit déjà à les distinguer.




FIGURE 1 – Image d'exemple : perroquets décomposés en ses composantes RGB.

2. HSV : Divise la couleur en Hue (teinte), Saturation et Value (intensité).

Focus : le canal Hue décrit la couleur « pure » indépendamment de la luminosité ; le canal Value indique l'intensité de la lumière.




FIGURE 2 – Image d'exemple : perroquets décomposés en ses composantes HSV.

3. YCbCr : Sépare l'image en Y (luminance) et Cb/Cr (canaux de chrominance).

Focus : utile pour séparer la luminosité de la couleur ; permet de travailler avec des couleurs cohérentes même en présence de variations d'éclairage.




FIGURE 3 – Image d'exemple : perroquets décomposés en ses composantes YCbCr.

Question 2

Quelles sont les limites de l'utilisation des seules couleurs comme espace d'observation (caractéristiques) ? Quelles autres caractéristiques pouvez-vous proposer pour la segmentation d'images ?

Chaque modèle de segmentation présente des limites, que l'on peut résumer comme suit :

- **RGB** : Très sensible à l'éclairage. Ne sépare pas efficacement les objets de couleurs similaires. Mélange l'information de couleur et d'intensité.
- **HSV** : Plus robuste à l'éclairage, mais les régions à faible saturation peuvent générer des ambiguïtés. Ignore toujours la forme et la texture.
- **YCbCr** : Peut ne pas distinguer des couleurs proches. Ne capture pas la texture ni les contours.

Sur cette base, on peut proposer certaines améliorations et caractéristiques utiles pour la segmentation. On peut utiliser l'opérateur de Sobel et la magnitude du gradient pour détecter les changements spatiaux (contours et bordures). Ajouter de l'information spatiale (par exemple, une feature $[R, G, B, x, y]$) permet d'éviter que des pixels éloignés mais de même couleur soient regroupés.

L'utilisation combinée de plusieurs méthodes de segmentation permet une amélioration considérable. On peut notamment souligner l'usage de YCbCr ou HSV pour traiter les problèmes liés à la luminance, et l'usage de RGB associé à l'information spatiale pour mieux gérer la couleur.

Classification de caractéristiques locales

Dans ce TP, nous nous intéressons à la segmentation d'images par classification de caractéristiques locales. Pour cela, nous utiliserons le dataset Kitti, qui contient des scènes routières en milieu forestier. L'objectif est d'isoler les pixels correspondant à la route, afin de segmenter la voie navigable dans le cadre d'une application de conduite assistée ou autonome.

La segmentation par caractéristiques locales consiste à représenter chaque pixel à l'aide de features décrivant la couleur, la texture, ou d'autres informations spatiales, puis à classer ces pixels en différentes classes (par exemple : route vs non-route). Cette approche permet de traiter des images complexes en exploitant des informations locales, plutôt que de simplement se baser sur la couleur globale.

Les principaux problèmes pour ce dataset sont : les variations de luminosité qui affectent les couleurs, et le fait que les contours soient ignorés lorsque l'on se base uniquement sur la couleur. Par conséquent, nous pouvons d'abord analyser certaines images en utilisant la segmentation HSV, puis compléter cette analyse par un traitement des contours pour prendre en compte la structure des objets.




FIGURE 4 – Image d'exemple : image 063 avec la segmentation HSV.




FIGURE 5 – Image d'exemple : contour d'image 063 dans la composante valeur.

Classification bayésienne des pixels

QDA et GaussianNB

Les deux classifieurs utilisés reposent sur le cadre bayésien gaussien : chaque classe C_k est modélisée par une loi gaussienne multivariée, et la règle de décision consiste à assigner à chaque pixel la classe qui maximise la probabilité a posteriori $P(C_k | x)$.

Analyse Discriminante Quadratique (QDA). Le QDA est un classifieur bayésien gaussien **multidimensionnel**. Il estime, pour chaque classe C_k , une moyenne μ_k et une matrice de covariance Σ_k propre à cette classe :

$$P(x | C_k) = \frac{1}{(2\pi)^{d/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k)\right)$$

La matrice Σ_k capture les corrélations entre les différentes composantes de x (ici, les canaux de couleur). La frontière de décision entre deux classes est une *quadrique* (ellipse, parabole ou hyperbole selon les covariances), d'où le nom du modèle. Le paramètre `priors=None` entraîne l'estimation des probabilités a priori $P(C_k)$ à partir des fréquences observées dans les ROI, ce qui revient à appliquer la règle MAP.

Classifieur bayésien naïf gaussien (GaussianNB). Le GaussianNB simplifie le modèle en supposant que les composantes de x sont **conditionnellement indépendantes** sachant la classe :

$$P(x | C_k) = \prod_{j=1}^d \mathcal{N}(x_j | \mu_{kj}, \sigma_{kj}^2)$$

Chaque canal est donc modélisé séparément par une gaussienne univariée de moyenne μ_{kj} et de variance σ_{kj}^2 . Cette hypothèse revient à supposer que Σ_k est diagonale, ce qui réduit considérablement le nombre de paramètres à estimer et accélère l'apprentissage. En contrepartie, si les canaux sont corrélés, le modèle est mal spécifié et la frontière de décision peut être sous-optimale.

En résumé, le QDA est plus expressif mais nécessite davantage de données pour estimer correctement Σ_k , tandis que le GaussianNB est plus robuste au manque de données mais moins précis lorsque l'hypothèse d'indépendance est violée.

Question 3

Quelles vous semblent être les espaces d'observations et le nombre de classes le mieux adaptés à la tâche qui vous intéresse ? Quelles sont les difficultés potentielles ? Quelles différences observez-vous entre le modèle bayésien gaussien multidimensionnel et le modèle bayésien gaussien naïf ?

Choix de l'espace d'observation

Pour la classification bayésienne des pixels de la route dans le dataset KITTI, nous avons expérimenté trois espaces de couleur : BGR, HSV et YCbCr, en utilisant deux modèles distincts — l'analyse discriminante quadratique (QDA) et le classifieur bayésien naïf gaussien (GaussianNB) — sur les mêmes régions d'intérêt annotées.

Espace BGR : Dans l'espace natif de la caméra, les deux modèles produisent des résultats acceptables mais imparfaits. Le QDA surpasse nettement le GaussianNB, ce qui s'explique par la corrélation entre les canaux B, G et R — corrélation que le modèle naïf ignore par hypothèse d'indépendance. La route, dont la couleur grise mélange de manière cohérente les trois canaux, est mal modélisée par le GaussianNB en BGR.

Espace HSV : Cet espace améliore la robustesse à l'éclairage grâce à la séparation entre teinte et intensité. Cependant, il introduit un bruit important dans les régions de végétation dense, où le canal *Hue* présente une forte variabilité. Les deux modèles identifient correctement la route, mais la présence de faux positifs dans les zones forestières limite l'exploitabilité du résultat.

Espace YCbCr : C'est l'espace qui produit les meilleurs résultats pour cette tâche. En séparant la luminance Y des composantes de chrominance Cb et Cr , il rend la classification moins sensible aux variations d'éclairage. Dans cet espace, le QDA et le GaussianNB donnent des résultats très similaires et tous deux identifient correctement la région de route, ce qui suggère que les canaux de YCbCr sont peu corrélés entre eux pour les pixels de route — rendant l'hypothèse d'indépendance du modèle naïf plus valide.




FIGURE 6 – Résultats de la classification bayésienne (QDA et GaussianNB) sur l'image 032 pour les espaces BGR, HSV et YCbCr. Les pixels blancs correspondent à la classe *route* (positif).

Nombre de classes

Nous avons opté pour une classification binaire : *route* (positif) et *non-route* (négatif). Ce choix est directement adapté à l'objectif applicatif — la délimitation de la voie navigable — et évite la complexité supplémentaire d'une classification multi-classes, dont l'interprétation serait moins directe pour une application de conduite assistée.

Difficultés potentielles

La principale difficulté observée est la présence de **zones d'ombre sur la chaussée**, qui modifient localement les valeurs des pixels de route et les rapprochent chromatiquement d'autres régions de la scène. Ces zones peuvent être mal classifiées, notamment en espace BGR où luminance et chrominance ne sont pas découplées. L'espace YCbCr atténue ce problème grâce à la composante *Y*, mais ne l'élimine pas complètement.

Par ailleurs, la qualité du modèle dépend fortement du **choix et de la représentativité des ROI** annotées manuellement. Des ROI trop homogènes ou trop restreintes peuvent conduire à un modèle qui ne généralise pas bien à l'ensemble de la scène.

Différences entre QDA et GaussianNB

Le modèle QDA (*Quadratic Discriminant Analysis*) est un classifieur bayésien gaussien **multidimensionnel** : il modélise la distribution de chaque classe par une gaussienne multivariée avec une matrice de covariance propre à chaque classe, capturant ainsi les corrélations entre les

canaux de couleur.

Le GaussianNB (*Gaussian Naïve Bayes*) est un classifieur bayésien **naïf** : il suppose que les canaux sont conditionnellement indépendants sachant la classe, ce qui revient à modéliser chaque canal séparément avec une gaussienne univariée. Cette hypothèse simplifie considérablement le modèle mais peut introduire des erreurs lorsque les canaux sont corrélés.

En pratique, cette différence se traduit de la manière suivante :

- En **BGR**, le QDA est nettement supérieur au GaussianNB, car les canaux B, G et R sont fortement corrélés pour les pixels de route grise. Le modèle naïf ne capture pas cette structure et produit une frontière de décision moins précise.
- En **YCbCr**, les deux modèles donnent des résultats très comparables. La séparation de la luminance et de la chrominance rend les canaux moins corrélés, ce qui valide davantage l'hypothèse d'indépendance du GaussianNB dans cet espace.

Le meilleur résultat global est obtenu avec le **GaussianNB en espace YCbCr**, qui combine la robustesse à l'éclairage de cet espace et la simplicité du modèle naïf, suffisante lorsque les canaux sont peu corrélés.

Classification non supervisée des pixels par K-Means

Algorithme K-Means

L'algorithme K-Means est une méthode de **classification non supervisée** qui partitionne un ensemble de N observations en K groupes (clusters) en minimisant la somme des distances intra-cluster. Formellement, il cherche à minimiser l'inertie totale :

$$J = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$$

où μ_k est le centroïde (centre de masse) du cluster C_k .

L'algorithme procède de manière itérative en deux étapes :

1. **Affectation** : chaque observation x_i est assignée au cluster dont le centroïde est le plus proche au sens de la distance euclidienne :

$$c_i = \arg \min_k \|x_i - \mu_k\|^2$$

2. **Mise à jour** : les centroïdes sont recalculés comme la moyenne des observations affectées à chaque cluster :

$$\mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$$

Ces deux étapes sont répétées jusqu'à convergence, c'est-à-dire jusqu'à ce que les affectations ne changent plus. L'algorithme est garanti de converger, mais vers un minimum local de J , qui dépend de l'initialisation des centroïdes. L'option `n_init=10` de Scikit-Learn permet de relancer l'algorithme plusieurs fois avec des initialisations différentes et de retenir la partition de moindre inertie.

Contrairement à l'approche bayésienne, K-Means ne requiert **aucune annotation** : les classes émergent directement de la structure des données. En contrepartie, le nombre de clusters K doit

être fixé a priori, et rien ne garantit qu'un cluster corresponde à une classe sémantiquement significative (comme la route).

Dans le contexte de la segmentation d'images, chaque pixel est représenté par son vecteur de couleur $x \in \mathbb{R}^3$ dans l'espace choisi (BGR, HSV ou YCbCr), et K-Means regroupe les pixels de couleurs similaires en K clusters, produisant une image segmentée où chaque région homogène est identifiée par un label entier.

Question 4

Quelles vous semblent être les espaces d'observations et le nombre de classes le mieux adaptés à la tâche qui vous intéresse ? Quelles sont les difficultés potentielles ? Quels sont les avantages et les inconvénients par rapport à l'approche précédente ?

Choix de l'espace d'observation








Pour la segmentation de la route dans les scènes du dataset KITTI, nous avons expérimenté trois espaces de couleur : BGR, HSV et YCbCr. L'objectif est de déterminer lequel offre la meilleure séparation entre la classe *route* et le reste de la scène (végétation, ciel, véhicules).

L'espace BGR est l'espace natif de la caméra et ne sépare pas la luminance de la chrominance. Cependant, dans les scènes routières du dataset KITTI, la route présente une signature chromatique relativement stable (tons gris-beige), ce qui permet à K-Means de l'isoler efficacement. L'espace HSV sépare la teinte (*Hue*) de la valeur (*Value*), ce qui semblait a priori avantageux. Néanmoins, dans nos expériences, cet espace a introduit davantage de bruit dans les clusters, en raison de la forte sensibilité du canal *Hue* aux zones de faible saturation (zones grises comme la route). L'espace YCbCr, en découplant la luminance des composantes de chrominance, offre une alternative intéressante pour des scènes avec variations d'éclairage, mais ses résultats se sont avérés comparables à BGR sans avantage décisif pour cette tâche spécifique.

Conclusion : l'espace BGR s'est révélé le plus performant pour cette tâche, produisant des clusters moins bruités et une séparation plus nette de la région de route. Ce résultat s'explique par l'homogénéité chromatique des routes dans le dataset KITTI, qui rend la séparation directe dans l'espace BGR suffisante.

Choix du nombre de classes

Nous avons évalué $K \in \{4, 6, 8, 10\}$ afin de déterminer le nombre de clusters le mieux adapté à la tâche. Les figures suivantes présentent les résultats obtenus sur l'image 063 pour chaque valeur de K et chaque espace de couleur testé.

(a) BGR, $K = 4$ (b) BGR, $K = 6$ (c) BGR, $K = 8$ (d) BGR, $K = 10$ FIGURE 7 – Résultats K-Means en espace BGR pour $K \in \{4, 6, 8, 10\}$ sur l'image 063.(a) HSV, $K = 4$ (b) HSV, $K = 6$ (c) HSV, $K = 8$ FIGURE 8 – Résultats K-Means en espace HSV pour $K \in \{4, 6, 8\}$ sur l'image 063. L'espace HSV introduit davantage de bruit dans les clusters par rapport à BGR, notamment en raison de la sensibilité du canal *Hue* aux zones peu saturées.(a) YCbCr, $K = 6$ (b) YCbCr, $K = 8$ FIGURE 9 – Résultats K-Means en espace YCbCr pour $K \in \{6, 8\}$ sur l'image 063.

L'analyse de ces résultats met en évidence que $K = 8$ constitue le meilleur compromis. Pour $K < 8$, des régions visuellement distinctes — notamment les zones de végétation dense et la

chaussée — sont fusionnées dans un même cluster, ce qui nuit à l'identification de la voie navigable dans des scènes difficiles (présence de véhicules, ombres marquées ou forte luminosité). Pour $K > 8$, le nombre excessif de clusters fragmente la région de route en plusieurs sous-classes aux nuances peu significatives, introduisant du bruit qui complique l'interprétation du résultat final.

Généralisation inter-images

Une propriété importante de l'approche K-Means est la possibilité d'entraîner le modèle sur une image et de l'appliquer à une autre via la méthode `predict()`. Nous avons testé cette capacité en entraînant le modèle ($K = 8$, BGR) sur l'image 063 et en prédisant les clusters sur l'image 032, qui présente un véhicule en scène — condition absente dans l'image d'entraînement.




FIGURE 10 – Prédiction K-Means ($K = 8$, BGR) sur l'image 032, modèle entraîné sur l'image 063. Malgré la présence d'un véhicule, la région de route est correctement isolée, ce qui démontre une bonne capacité de généralisation du modèle.

Ce résultat démontre que le modèle K-Means, bien qu'entraîné de manière non supervisée sur une seule image, parvient à généraliser correctement à de nouvelles scènes présentant des conditions différentes. La route reste identifiable même en présence d'un véhicule occultant partiellement la chaussée, ce qui valide la robustesse de l'approche pour une application de conduite assistée.

Difficultés potentielles

L'algorithme K-Means présente néanmoins plusieurs limitations :

- **Sensibilité à l'initialisation** : Les résultats peuvent varier selon l'initialisation des centres de clusters. L'utilisation de `n_init=10` réduit cet effet en retenant la meilleure partition parmi plusieurs essais.
- **Absence de contrainte spatiale** : Des pixels éloignés mais de couleur similaire (par exemple, un trottoir gris et la chaussée) peuvent être regroupés dans le même cluster, rendant l'identification de la voie navigable ambiguë.
- **Nombre de classes fixé a priori** : Le choix de K requiert une validation expérimentale ; il n'existe pas de critère automatique universel pour les images naturelles.

Avantages et inconvénients par rapport à l'approche bayésienne

- **Avantages** : L'approche K-Means ne nécessite aucune annotation manuelle de régions d'intérêt (*ROI*), ce qui élimine le biais de sélection inhérent à l'approche supervisée et rend la méthode immédiatement applicable sans intervention humaine préalable.

- **Inconvénients :** Sans supervision, il n'est pas possible de garantir qu'un cluster corresponde exactement à la classe *route*. L'interprétation des clusters reste manuelle et subjective après le clustering. En revanche, la classification bayésienne, grâce aux ROI annotées par l'utilisateur, produit directement une carte binaire route / non-route, plus directement exploitable pour une application de conduite assistée ou autonome.

Conclusion

Ce travail pratique avait pour objectif de comparer deux approches de segmentation d'images par classification de pixels : la classification bayésienne (approche supervisée) et l'algorithme K-Means (approche non supervisée), appliquées à l'identification de la voie navigable dans les scènes routières du dataset KITTI.

Les expériences menées sur les espaces de couleur BGR, HSV et YCbCr ont montré que le choix de l'espace d'observation est déterminant pour la qualité de la segmentation. Dans les deux approches, l'espace YCbCr s'est distingué par sa robustesse aux variations d'éclairage, grâce au découplage entre luminance et chrominance. L'espace HSV, bien qu'intuitivement adapté, introduit un bruit excessif dans les régions de faible saturation comme la végétation. L'espace BGR, malgré son manque de séparation luminance/chrominance, s'est révélé suffisant pour le K-Means en raison de l'homogénéité chromatique des routes dans ce dataset.

Concernant la classification bayésienne, la comparaison entre le QDA et le GaussianNB a mis en évidence le rôle central de la corrélation entre canaux : en BGR, le QDA surpasse nettement le GaussianNB, dont l'hypothèse d'indépendance est violée. En YCbCr, les deux modèles convergent vers des résultats similaires, validant l'hypothèse naïve dans cet espace. Le meilleur résultat a été obtenu avec le GaussianNB en YCbCr.

Pour le K-Means, la valeur $K = 8$ s'est imposée comme le meilleur compromis : en deçà, des régions distinctes sont fusionnées ; au-delà, la fragmentation excessive introduit du bruit. La capacité de généralisation inter-images, démontrée par l'application du modèle entraîné sur l'image 063 à l'image 032 (contenant un véhicule), confirme la robustesse de l'approche non supervisée.

En termes de comparaison globale, les deux méthodes présentent des compromis distincts. La classification bayésienne produit directement une carte binaire route / non-route, exploitable sans post-traitement, mais requiert une annotation manuelle de ROI représentatives et est sensible au biais de sélection. Le K-Means, sans nécessiter d'annotation, explore la structure naturelle des données, mais l'identification du cluster correspondant à la route reste une étape manuelle et subjective.

Pour des applications de conduite assistée, où la fiabilité et l'interprétabilité sont primordiales, l'approche bayésienne supervisée en espace YCbCr apparaît comme la solution la plus directement exploitable. Le K-Means constitue néanmoins une alternative pertinente dans des contextes où les données annotées sont indisponibles ou coûteuses à produire.

Références

- [1] Manzanera, A. (2026). *CSC-4MI04 - Reconnaissance d'Images - Supports de cours*. ENSTA Paris.
- [2] Geiger, A., Lenz, P., Urtasun, R. *Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite*. Conference on Computer Vision and Pattern Recognition (CVPR), 2012. ([Disponible ici](#))
- [3] Geiger, A., Lenz, P., Stiller, C., Urtasun, R. *Vision meets Robotics : The KITTI Dataset*. International Journal of Robotics Research (IJRR), 2013. ([Disponible ici](#))